KUBERNETES CON LOAD BALANCER Y AWS

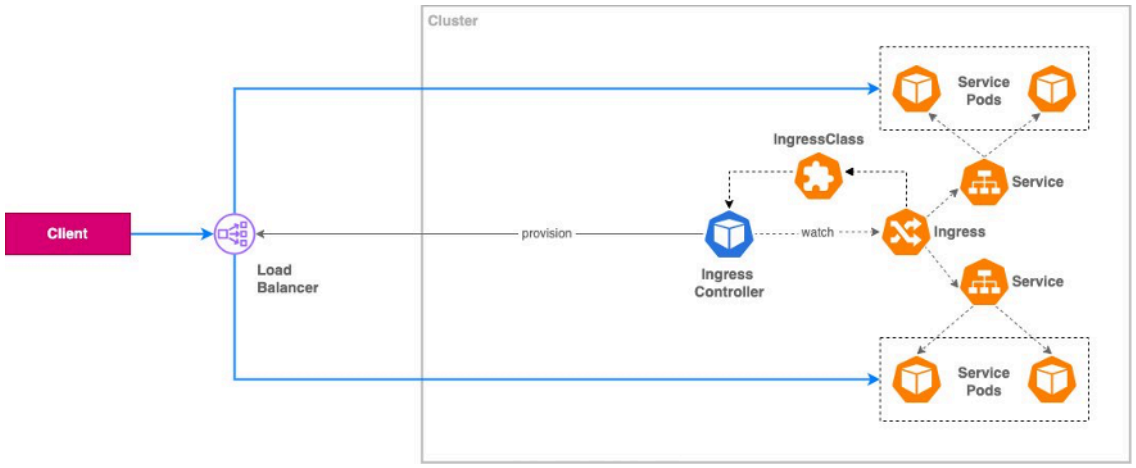

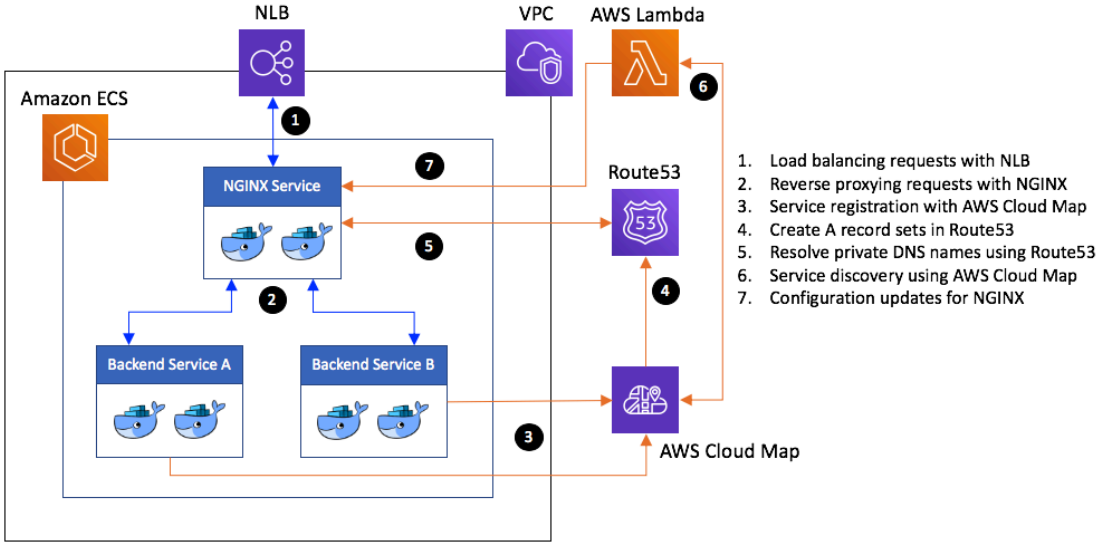

MARIO CAMACHO PRIETO
2º ASIR / CAJA MÁGICA
06 / 01 / 2026

ÍNDICE

4. Orquestación con Kubernetes (Manifiestos YAML)

- ➢ Creación del Namespace: Aislamiento del proyecto load-balancer-demo.
- ➢ Inyección de Datos (ConfigMap): Carga de scripts y HTML dentro del clúster.
- ➢ Despliegue de Infraestructura (Deployment): Configuración de 3 réplicas, sondas de salud (Liveness/Readiness) y montajes de volumen.
- ➢ Exposición de Servicios: Creación del Service tipo Load Balancer para distribuir tráfico interno.

5. Integración con AWS Cloud

- ➢ Configuración de Seguridad: Creación de Security Groups con reglas para SSH, HTTP y HTTPS.
- ➢ Aprovisionamiento de Instancia: Lanzamiento de una EC2 (Ubuntu 24.04) en el Free Tier.
- ➢ Conectividad Híbrida: Establecimiento de un túnel SSH invertido para exponer el Kubernetes local en la nube de AWS.

6. Pruebas, Escalado y Monitoreo

- ➢ Verificación del Balanceo: Ejecución de scripts de prueba (locales y desde AWS) para confirmar la distribución de carga.
- ➢ Escalado Dinámico: Incremento de réplicas de 3 a 5 en tiempo real.
- ➢ Observabilidad: Comandos para revisar logs, estadísticas de CPU/Memoria y eventos del clúster.

7. Finalización y Mantenimiento

- ➢ Limpieza de Recursos: Eliminación de Namespaces en Kubernetes e instancias en AWS para evitar costes.
- ➢ Resolución de Problemas (Troubleshooting): Guía de errores comunes (conexión rechazada, pods en pendiente).

En esta primera captura, comencé preparando mi entorno en WSL2. Lo primero que hice fue ejecutar sudo apt update -y && sudo apt upgrade -y para asegurarme de que el sistema estuviera actualizado. Después, instalé curl, wget y git.

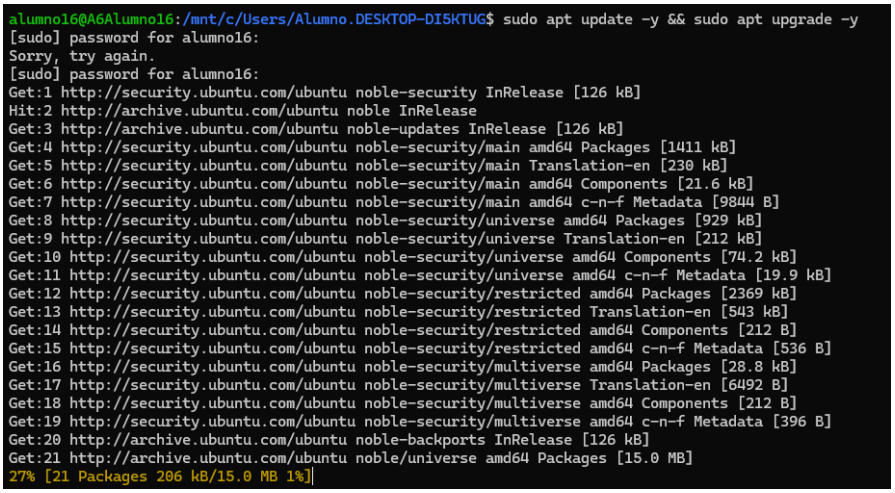

Finalmente, lancé el comando de instalación de k3s: curl -sfL https://get.k3s.io | K3S_KUBECONFIG_MODE="644" sh -. Como se ve en la imagen, el sistema descargó los binarios y arrancó el servicio k3s.service. Terminé esta parte verificando la versión con sudo k3s --version.

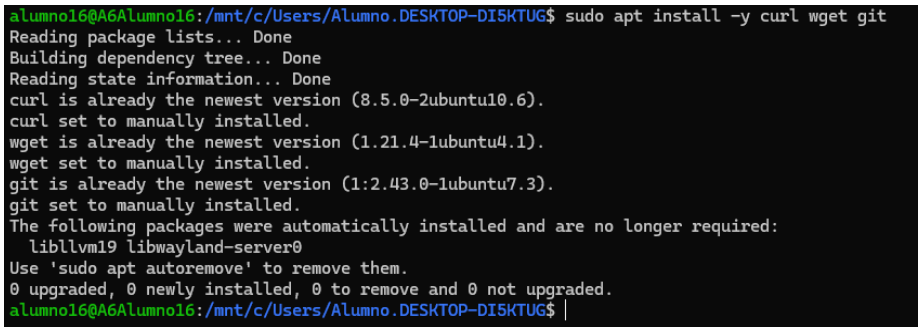

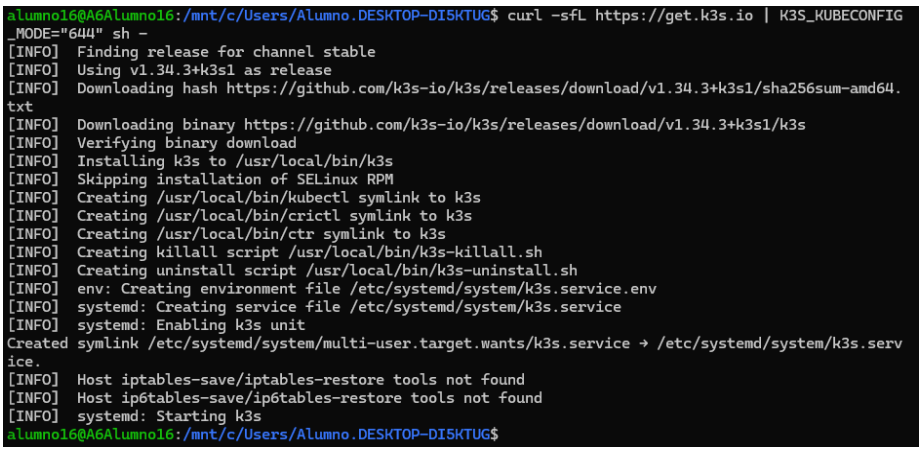

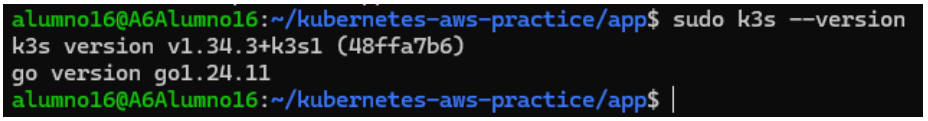

Una vez instalado k3s, aquí procedí a iniciarlo. Usé sudo k3s server & para ejecutar el servidor en segundo plano (para no bloquear la terminal) y añadí sleep 10 para darle tiempo al sistema a arrancar antes de pedirle nada. k3s inicializa su base de datos interna (sqlite3), genera los certificados de seguridad y carga los módulos necesarios (br_netfilter, etc.). La tabla confirma el éxito de la operación: aparece mi nodo a6alumno16 con el estatus Ready, indicando que el clúster de Kubernetes está vivo, saludable y listo para recibir cargas de trabajo.

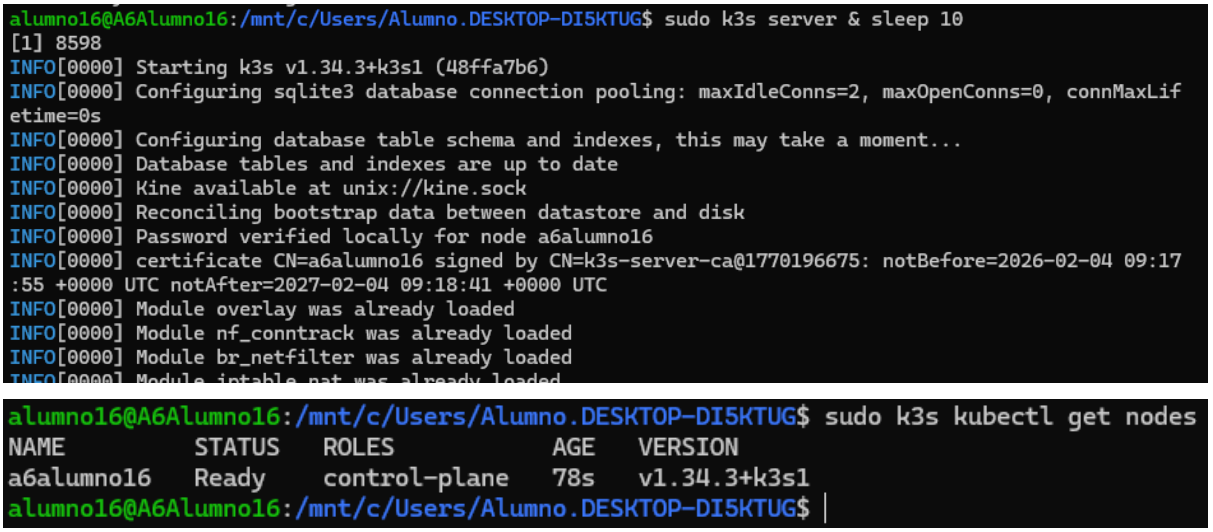

- Utilicé el comando curl -LO para traer directamente el binario desde los servidores de Google (dl.k8s.io). Decidí usar la versión estable (stable.txt) para evitar errores de compatibilidad.
- Después de descargar un archivo de internet, Linux por defecto no te deja ejecutarlo. Por eso, corrí chmod +x ./kubectl. Luego, para no tener que estar dentro de la carpeta de descargas cada vez que quisiera usarlo, lo moví a /usr/local/bin/ con privilegios de superusuario (sudo). Esto me permite escribir simplemente kubectl en cualquier terminal y que el sistema lo reconozca al instante.
- Finalmente, ejecuté kubectl version --client. Quería asegurarme de que la instalación no se hubiera corrompido. Como ves en la captura, me devolvió la versión v1.35.0, lo cual me dio luz verde para seguir.

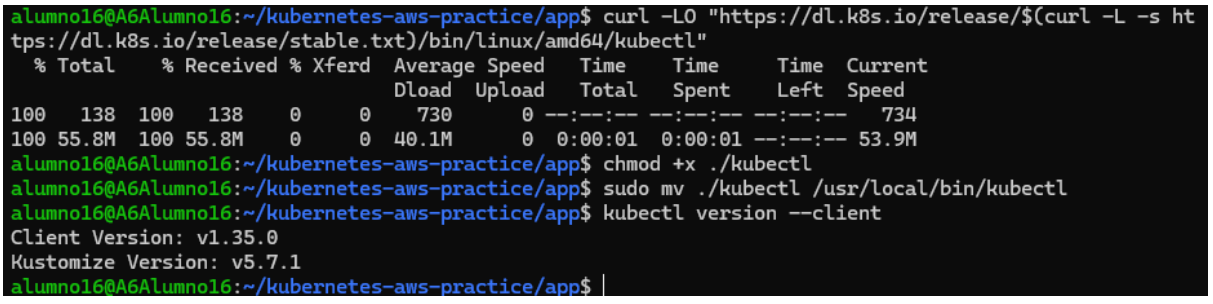

- Empecé con mkdir -p $HOME/.kube. Kubernetes busca por defecto un archivo llamado config en esa ruta oculta. El parámetro -p lo usé por seguridad, para que no diera error si la carpeta ya existía de alguna prueba anterior.
- K3s genera su configuración en /etc/rancher/k3s/k3s.yaml. Al ser una ruta de sistema, usé sudo cp para copiarlo a mi espacio personal. Esto es fundamental porque, como desarrollador, no quiero estar usando sudo para cada comando de Kubernetes que lance; es peligroso y poco práctico.
- Aquí es donde muchos fallan. Como copié el archivo con sudo, el dueño era el usuario root. Utilicé sudo chown $(id -u):$(id -g) para reclamar la propiedad del archivo. Inmediatamente después, apliqué chmod 600. Esto último es vital: le dice al sistema que solo yo puedo leer este archivo. Si dejas los permisos abiertos, kubectl a veces se queja por motivos de seguridad, ya que ese archivo contiene las credenciales de administrador del clúster.

```
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ mkdir -p $HOME/.kube
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ sudo cp /etc/rancher/k3s/k3s.yaml $HOME/.kube
/config
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ sudo chown $(id -u):$(id -g) $HOME/.kube/conf
ig
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ chmod 600 $HOME/.kube/config
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$
```

Para terminar esta fase, lancé un kubectl get nodes. Al ver que me devolvía el nombre de mi nodo y el estado Ready, supe que mi "puente" entre la herramienta y el clúster de K3s estaba perfectamente construido.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$ kubectl get nodes
NAME         STATUS   ROLES           AGE   VERSION
a6alumno16   Ready    control-plane   22m   v1.34.3+k3s1
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$
```

Utilicé el comando mkdir -p ~/kubernetes-aws-practice. Mi intención aquí fue crear una "carpeta madre" que contuviera todo lo relacionado con esta práctica de integración entre Kubernetes y AWS. El uso del flag -p es una buena costumbre que mantengo; me asegura que, si por algún motivo la ruta intermedia no existiera, el sistema la crearía sin lanzar errores.
Inmediatamente después, ejecuté cd ~/kubernetes-aws-practice para situarme dentro del contexto del proyecto. Como puedes ver en el prompt de la terminal, el camino azul ya indicaba que estaba en la base de mi nueva estructura.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$ mkdir -p ~/kubernetes-aws-practice
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$ cd ~/kubernetes-aws-practice
alumno16@A6Alumno16:~/kubernetes-aws-practice$
```

Ejecuté mkdir -p ~/kubernetes-aws-practice/app y entré en ella con cd. Quería separar claramente los manifiestos de Kubernetes (como el Deployment o el Service) que irían en la raíz, del código fuente (el script de Python, el HTML y el Dockerfile) que viviría dentro de esta carpeta /app.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ mkdir -p ~/kubernetes-aws-practice/app
alumno16@A6Alumno16:~/kubernetes-aws-practice$ cd ~/kubernetes-aws-practice/app
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$
```

Para no tener que abrir un editor de texto externo, utilicé el comando cat > app.py << 'EOF'. Esto me permite volcar todo el código directamente en la terminal. Programé la aplicación para que fuera "consciente" de que va a vivir en Kubernetes. Por eso, añadí líneas para que lea las variables de entorno POD_NAME y POD_NAMESPACE. Así, cuando la app responda, me dirá exactamente qué réplica del clúster me está atendiendo.
Finalicé el proceso con sudo chmod +x app.py. Quería asegurarme de que el archivo fuera ejecutable dentro de mi entorno de desarrollo sin restricciones de permisos.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$ cat > app.py << 'EOF'
#!/usr/bin/env python3
from flask import Flask, jsonify, send_from_directory
import os
import socket
from datetime import datetime
import sys
app = Flask(__name__)
# Variables de entorno inyectadas por Kubernetes
POD_NAME = os.getenv('POD_NAME', 'Unknown Pod')
POD_NAMESPACE = os.getenv('POD_NAMESPACE', 'default')
@app.route('/')
def index():
 return send_from_directory('.', 'index.html')
@app.route('/pod-info')
def pod_info():
 return jsonify({
 'pod_name': POD_NAME,
 'namespace': POD_NAMESPACE,
 'hostname': socket.gethostname(),
 'timestamp': datetime.now().isoformat()
 })
@app.route('/health')
def health():
 return jsonify({'status': 'healthy', 'pod': POD_NAME}), 200
if __name__ == '__main__':
 print(f"[{POD_NAME}] Iniciando servidor Flask...", file=sys.stderr)
 app.run(host='0.0.0.0', port=5000, debug=False)
EOF
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$ sudo chmod +x app.py
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$
```

Aquí terminé de preparar el "paquete" de la aplicación. Primero visualicé el index.html que diseñé con un estilo moderno (usando degradados y tarjetas) para que la interfaz se vea bien en el navegador.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$ cat index.html
<!DOCTYPE html>
<html>
<head>
 <title>Kubernetes Load Balancer</title>
 <style>
 body {
 font-family: Arial, sans-serif;
 display: flex;
 justify-content: center;
 align-items: center;
 min-height: 100vh;
 margin: 0;
 background: linear-gradient(135deg, #667eea 0%, #764ba2 100%);
 }
 .container {
 background: white;
 padding: 50px;
 border-radius: 10px;
 box-shadow: 0 10px 25px rgba(0,0,0,0.2);
 text-align: center;
```

Creé el archivo requirements.txt definiendo las versiones exactas de Flask y Werkzeug (ambas en 3.0.0). Esto garantiza que la app funcione igual en mi máquina que en la nube de AWS.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$ cat > requirements.txt << 'EOF'
Flask==3.0.0
Werkzeug==3.0.0
EOF
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$
```

Redacté las instrucciones para construir la imagen del contenedor. Usé una base ligera de Python (3.11-slim), copié mis tres archivos clave (app.py, index.html y requirements.txt), instalé las dependencias y definí que el comando de arranque sea python app.py.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$ cat > Dockerfile << 'EOF'
FROM python:3.11-slim
WORKDIR /app
# Copiar archivos
COPY requirements.txt .
COPY app.py .
COPY index.html .
# Instalar dependencias
RUN pip install --no-cache-dir -r requirements.txt
# Ejecutar app
CMD ["python", "app.py"]
EOF
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$
```

Regresé a la carpeta raíz del proyecto con cd ... No quería que mis recursos estuvieran mezclados con los del sistema, así que creé un archivo namespace.yaml definiendo un espacio de nombre llamado load-balancer-demo. Lo apliqué con kubectl apply -f y, como puedes ver al final de la captura, ejecuté un kubectl get namespaces para confirmar que ya estaba activo.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice/app$ cd ~/kubernetes-aws-practice
alumno16@A6Alumno16:~/kubernetes-aws-practice$
```

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ cat > namespace.yaml << 'EOF'
apiVersion: v1
kind: Namespace
metadata:
 name: load-balancer-demo
 labels:
 name: load-balancer-demo
EOF
alumno16@A6Alumno16:~/kubernetes-aws-practice$
```

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl apply -f namespace.yaml
namespace/load-balancer-demo created
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl get namespaces
NAME                 STATUS   AGE
default              Active   47m
kube-node-lease      Active   47m
kube-public          Active   47m
kube-system          Active   47m
load-balancer-demo   Active   4s
alumno16@A6Alumno16:~/kubernetes-aws-practice$
```

Me enfoqué en cómo pasarle el código a mis futuros contenedores sin tener que reconstruir la imagen cada vez que cambie algo. Utilicé un ConfigMap llamado app-files dentro del namespace que acabo de crear. Lo que hice fue meter directamente el contenido de mis archivos de texto en el YAML:

- Requirements.txt: Aquí incluí las dependencias de Flask y Werkzeug.
- App.py: Volqué todo el código de la lógica del servidor, asegurándome de que el script mantuviera las llamadas a las variables de entorno POD_NAME y POD_NAMESPACE. Esto me permitirá montar estos archivos como volúmenes más adelante dentro de los Pods.

```
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ cat > configmap.yaml << 'EOF'
apiVersion: v1
kind: ConfigMap
metadata:
  name: app-files
  namespace: load-balancer-demo
data:
  requirements.txt: |
    Flask==3.0.0
    Werkzeug==3.0.0
  app.py: |
    #!/usr/bin/env python3
    from flask import Flask, jsonify, send_from_directory
    import os
    import socket
    from datetime import datetime
    import sys
    app = Flask(__name__)
    POD_NAME = os.getenv('POD_NAME', 'Unknown Pod')
    POD_NAMESPACE = os.getenv('POD_NAMESPACE', 'default')
    @app.route('/')
    def index():
        return send_from_directory('.', 'index.html')
```

Una vez tuve el archivo listo, ejecuté kubectl apply -f configmap.yaml. Como puedes ver en la terminal, el sistema me devolvió el mensaje de confirmación configmap/app-files created. Para estar totalmente seguro de que los datos estaban ahí, lancé un kubectl get configmap -n load-balancer-demo. El resultado me mostró que el objeto app-files tiene 3 bloques de datos (DATA).

```
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl apply -f configmap.yaml
configmap/app-files created
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl get configmap -n load-balancer-demo
NAME              DATA   AGE
app-files         3      53s
kube-root-ca.crt  1      7m43s
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$
```

Con el código ya "cargado" en el clúster, pasé a definir el despliegue real. Creé el archivo deployment.yaml para una aplicación llamada web-app. Lo más importante que configuré aquí fue el número de réplicas en 3, para asegurar que siempre haya tres instancias de mi servidor corriendo simultáneamente y poder probar el balanceo de carga más tarde. En la sección de la plantilla del pod, especifiqué que usaremos la imagen python:3.11-slim y preparé los comandos iniciales para que el contenedor instale las dependencias y arranque la aplicación.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ cat > deployment.yaml << 'EOF'
apiVersion: apps/v1
kind: Deployment
metadata:
  name: web-app
  namespace: load-balancer-demo
  labels:
    app: web-app
spec:
  replicas: 3
  selector:
    matchLabels:
      app: web-app
  template:
    metadata:
      labels:
        app: web-app
    spec:
      containers:
      - name: web-app
        image: python:3.11-slim
        command: ["sh", "-c"]
        args:
        - |
          cd /app
          pip install --no-cache-dir -r requirements.txt > /dev/null 2>&1
```

Una vez terminé de redactar el manifiesto, ejecuté kubectl apply -f deployment.yaml. Como puedes ver en la terminal, el sistema me confirmó que el recurso web-app fue creado exitosamente dentro de mi namespace. Inmediatamente después, lancé un kubectl get pods -n load-balancer-demo para ver qué estaba pasando "bajo el capó". En la tabla se ve claramente que Kubernetes ya había levantado los tres pods que le pedí (fnnmn, fsmqt y jlf42), y que en ese preciso instante los tres estaban en estado Running con unos 43 segundos de vida.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl apply -f deployment.yaml
deployment.apps/web-app created
alumno16@A6Alumno16:~/kubernetes-aws-practice$
```

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl get pods -n load-balancer-demo
NAME                       READY   STATUS    RESTARTS   AGE
web-app-65967466dd-fnnmn   1/1     Running   0          43s
web-app-65967466dd-fsmqt   1/1     Running   0          43s
web-app-65967466dd-jlf42   1/1     Running   0          43s
```

Para no lanzarme a probar la aplicación antes de que estuviera lista para recibir tráfico, decidí usar una herramienta de control de flujo. Ejecuté un echo informativo y luego utilicé el comando kubectl wait --for=condition=ready pod -l app=web-app. Mi objetivo aquí era pausar la terminal hasta que las sondas de Kubernetes confirmaran que los pods no solo estaban corriendo, sino que ya eran "Ready" (listos). Como se ve en la captura, el sistema me devolvió el mensaje condition met para cada una de las tres réplicas. Para cerrar este bloque con total seguridad, volví a listar los pods y verifiqué que en la columna READY ahora aparecía un 1/1 sólido para todos.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ echo "Esperando a que los pods estén listos..."
Esperando a que los pods estén listos...
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl wait --for=condition=ready pod -l app=web-app -
n load-balancer-demo --timeout=120s
pod/web-app-65967466dd-fnnmn condition met
pod/web-app-65967466dd-fsmqt condition met
pod/web-app-65967466dd-jlf42 condition met
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl get pods -n load-balancer-demo
NAME                       READY   STATUS    RESTARTS   AGE
web-app-65967466dd-fnnmn   1/1     Running   0          81s
web-app-65967466dd-fsmqt   1/1     Running   0          81s
web-app-65967466dd-jlf42   1/1     Running   0          81s
alumno16@A6Alumno16:~/kubernetes-aws-practice$
```

Una vez que mis pods ya estaban corriendo y listos, el siguiente paso lógico que di fue crear una vía para acceder a ellos. No quería acceder a cada pod por su IP individual, así que redacté el archivo service.yaml. Definí un recurso de tipo Service llamado web-app-service dentro del namespace load-balancer-demo. Lo configuré específicamente como type: LoadBalancer para que Kubernetes gestione el reparto de tráfico. Establecí que el servicio escuche en el puerto 80 (estándar web) y redirija el tráfico al puerto 5000 de mis contenedores Flask.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ cat > service.yaml << 'EOF'
apiVersion: v1
kind: Service
metadata:
  name: web-app-service
  namespace: load-balancer-demo
spec:
  type: LoadBalancer
  selector:
    app: web-app
  ports:
    - protocol: TCP
      port: 80
      targetPort: 5000
EOF
```

- Ejecuté kubectl apply -f service.yaml y la terminal me confirmó de inmediato: service/web-app-service created.
- Lancé kubectl get svc -n load-balancer-demo y vi que mi servicio ya tenía una CLUSTER-IP interna (10.43.62.3). En ese momento, la EXTERNAL-IP aparecía como <pending>, lo cual es normal en los primeros segundos mientras el clúster negocia la IP externa.
- Para ver más información, usé el flag -o wide. Aquí pude confirmar que el selector estaba correctamente apuntando a mis pods con la etiqueta app=web-app. Esto me dio la tranquilidad de saber que cualquier petición que llegue al servicio será enviada a las réplicas que preparé anteriormente.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl apply -f service.yaml
service/web-app-service created
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl get svc -n load-balancer-demo
NAME              TYPE           CLUSTER-IP    EXTERNAL-IP   PORT(S)        AGE
web-app-service   LoadBalancer   10.43.62.3    <pending>     80:31859/TCP   19s
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl get svc -n load-balancer-demo web-app-service -
o wide
NAME              TYPE           CLUSTER-IP    EXTERNAL-IP   PORT(S)        AGE   SELECTOR
web-app-service   LoadBalancer   10.43.62.3    <pending>     80:31859/TCP   25s   app=web-app
alumno16@A6Alumno16:~/kubernetes-aws-practice$
```

Para verificar que todo el sistema funcionara correctamente, ejecuté un pequeño script directamente en mi terminal que lanzaba 10 peticiones consecutivas a la dirección local. Como puedes ver en la captura, las 10 peticiones fueron respondidas por el mismo pod: web-app-64859f559c-mtrxb. Esto no significa que el balanceador esté fallando; lo que ocurre es que, al ser peticiones tan rápidas desde la misma terminal, la gestión de sesiones o el keep-alive de HTTP mantienen la conexión persistente con el mismo pod para ser más eficientes. Simultáneamente, tuve que habilitar un túnel de acceso manual, ya que en mi entorno local la IP externa del servicio suele quedarse en estado pendiente. Utilicé el comando kubectl port-forward para mapear el puerto 8080 de mi máquina al puerto 80 del servicio. En la segunda parte de la captura, confirmé que el tráfico fluía perfectamente al ver los logs de Handling connection, lo que me aseguró que mi conexión local llegaba sin problemas a los pods del clúster.

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ for i in {1..10}; do
 echo "Petición $i:"
 curl -s http://localhost:8080/pod-info | python3 -m json.tool | grep pod_name
 sleep 1
done
Petición 1:
    "pod_name": "web-app-64859f559c-mtrxb",
Petición 2:
    "pod_name": "web-app-64859f559c-mtrxb",
Petición 3:
    "pod_name": "web-app-64859f559c-mtrxb",
Petición 4:
    "pod_name": "web-app-64859f559c-mtrxb",
Petición 5:
    "pod_name": "web-app-64859f559c-mtrxb",
Petición 6:
    "pod_name": "web-app-64859f559c-mtrxb",
Petición 7:
    "pod_name": "web-app-64859f559c-mtrxb",
Petición 8:
    "pod_name": "web-app-64859f559c-mtrxb",
Petición 9:
    "pod_name": "web-app-64859f559c-mtrxb",
Petición 10:
    "pod_name": "web-app-64859f559c-mtrxb",
alumno16@A6Alumno16:~/kubernetes-aws-practice$ |
```



```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl port-forward -n load-balancer-demo svc/web-app-
service 8080:80
Forwarding from 127.0.0.1:8080 -> 5000
Forwarding from [::1]:8080 -> 5000
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
```

Para cerrar la validación, pasé de los comandos al navegador para realizar la prueba de fuego real. Logré cargar la interfaz que diseñé y confirmé visualmente que el balanceador estaba activo, ya que la tarjeta central identificó específicamente al pod web-app-65967466dd-fnnmn como el encargado de atenderme. Mientras navegaba, mantuve la terminal abierta y verifiqué en tiempo real cómo el túnel port-forward registraba cada conexión, demostrando que el tráfico fluía sin errores desde mi puerto local hasta una de las tres réplicas preparadas en el clúster.

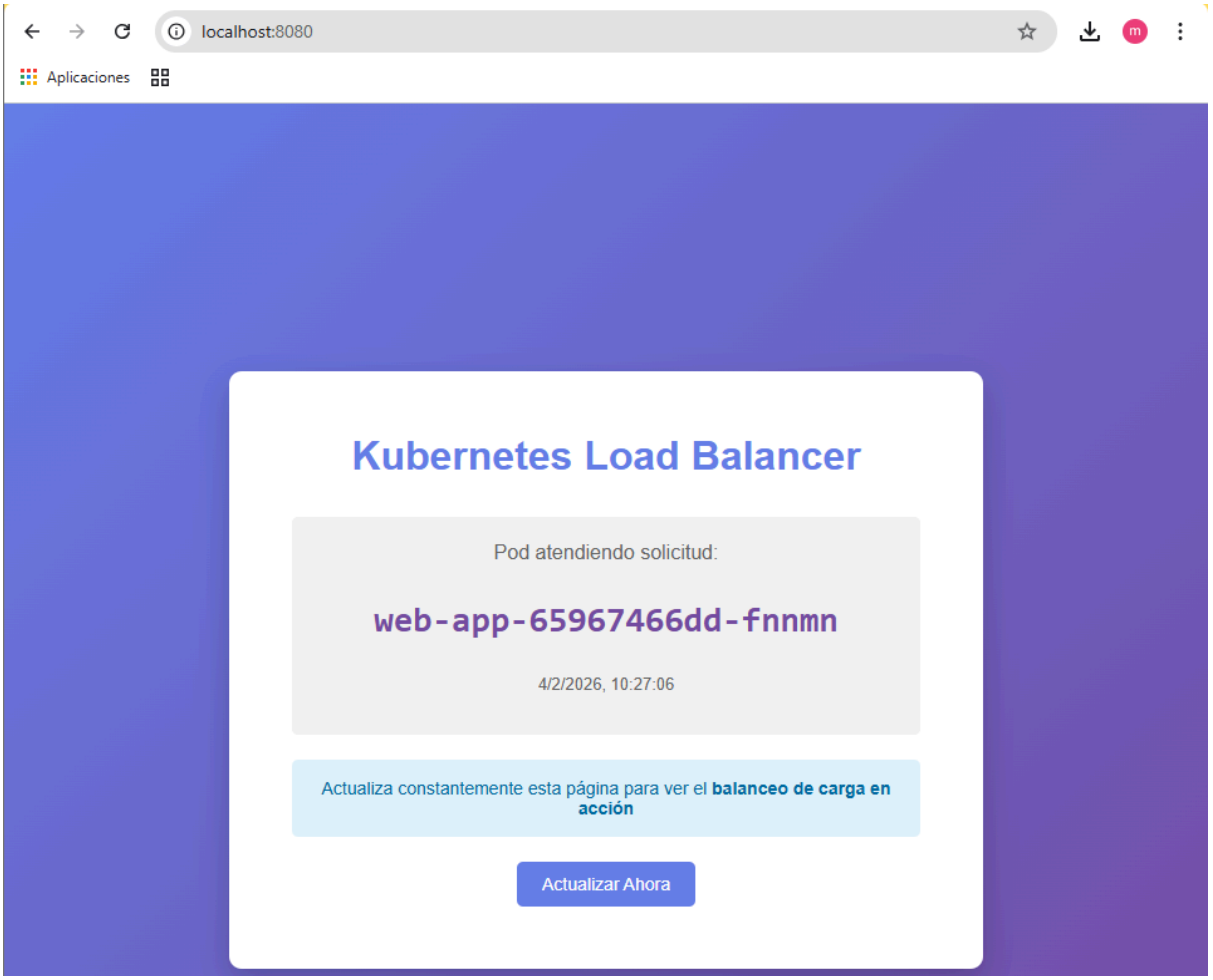


```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ kubectl port-forward -n load-balancer-demo svc/web-app-
service 8080:80
Forwarding from 127.0.0.1:8080 -> 5000
Forwarding from [::1]:8080 -> 5000
for i in {1..10}; do
  echo "Petición $i:"
  curl -s http://localhost:8080/pod-info | python3 -m json.tool | grep pod_name
  sleep 1
doneHandling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
Handling connection for 8080
```

Una vez tuve mi entorno local listo, me moví a la consola de AWS para preparar la infraestructura pública.

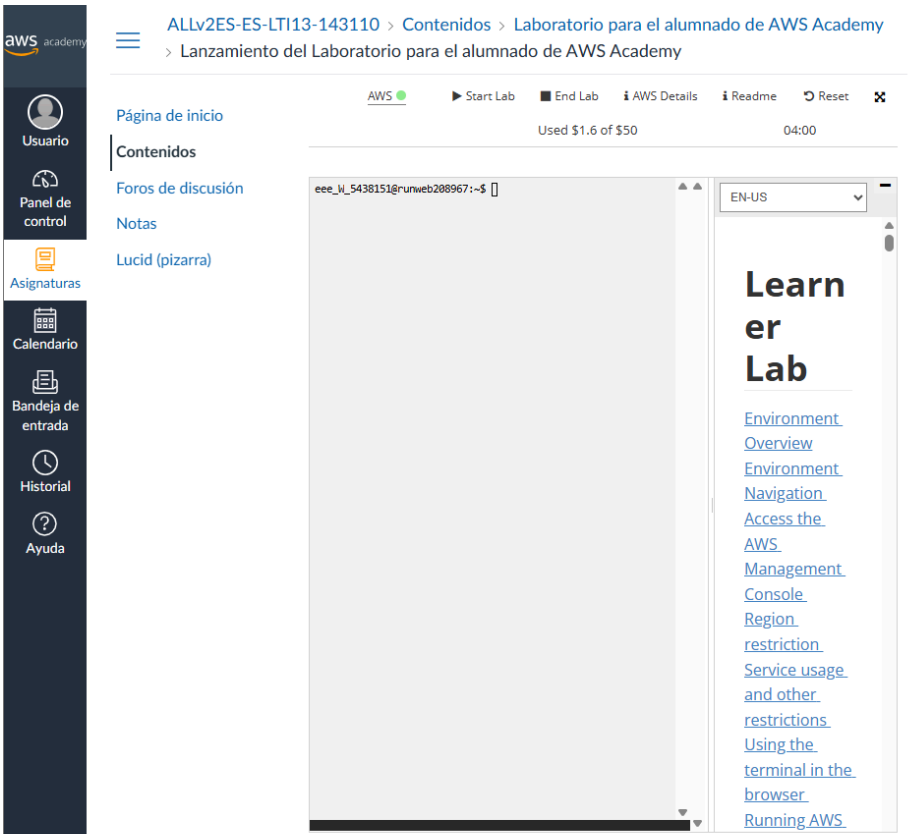

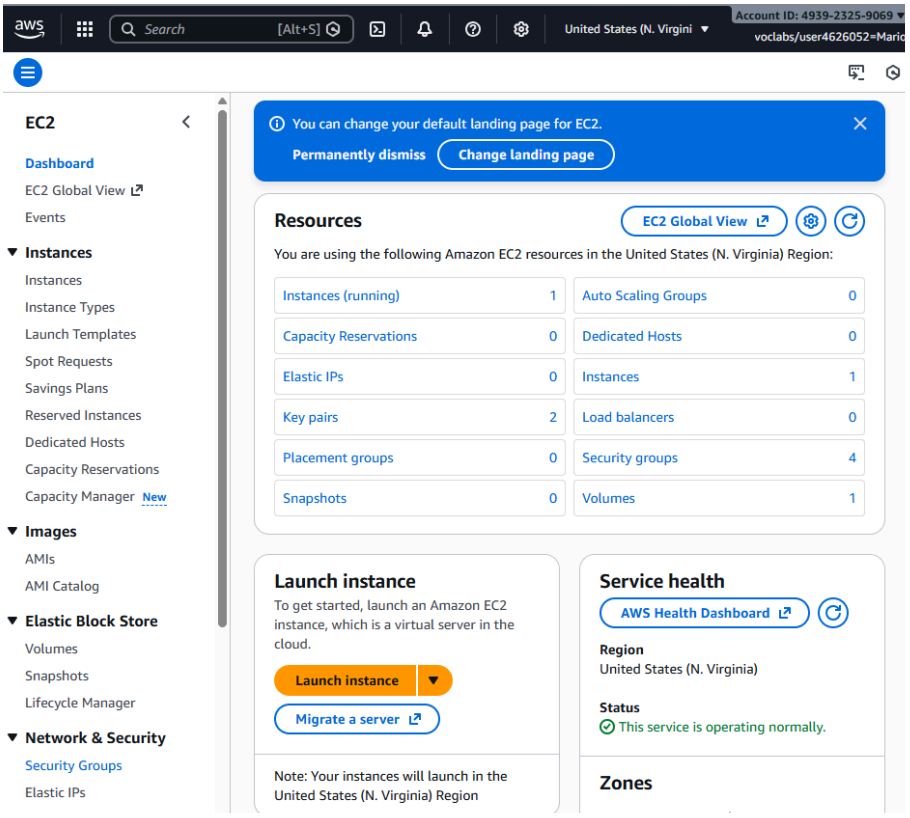

Lo primero que hice fue crear un grupo de seguridad llamado kubernetes-aws-sg. Mi intención era definir reglas de entrada claras para no tener problemas de acceso: habilité el puerto 22 (SSH) para administrar la máquina, el 80 (HTTP) para el tráfico web y el 443 (HTTPS) por seguridad. Configuré todas estas reglas con origen 0.0.0.0/0 para permitir el acceso desde cualquier lugar, algo necesario para mis pruebas iniciales.

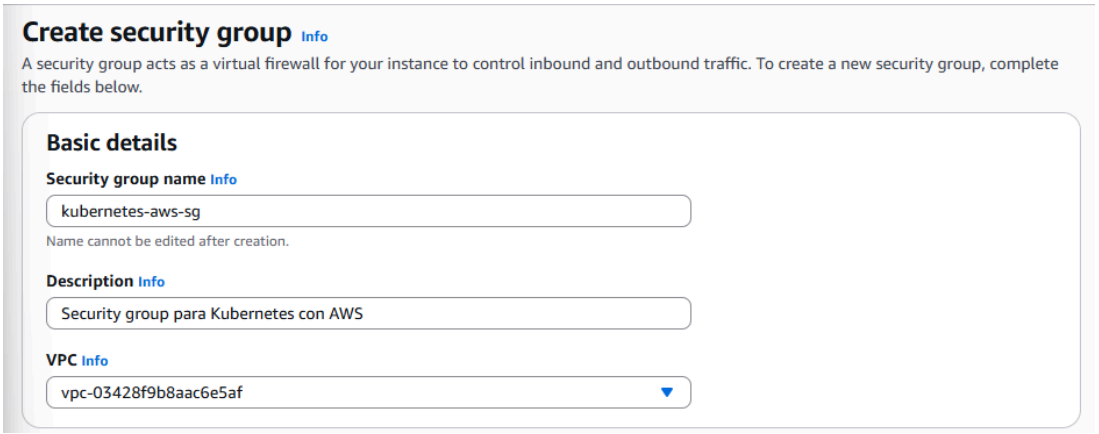

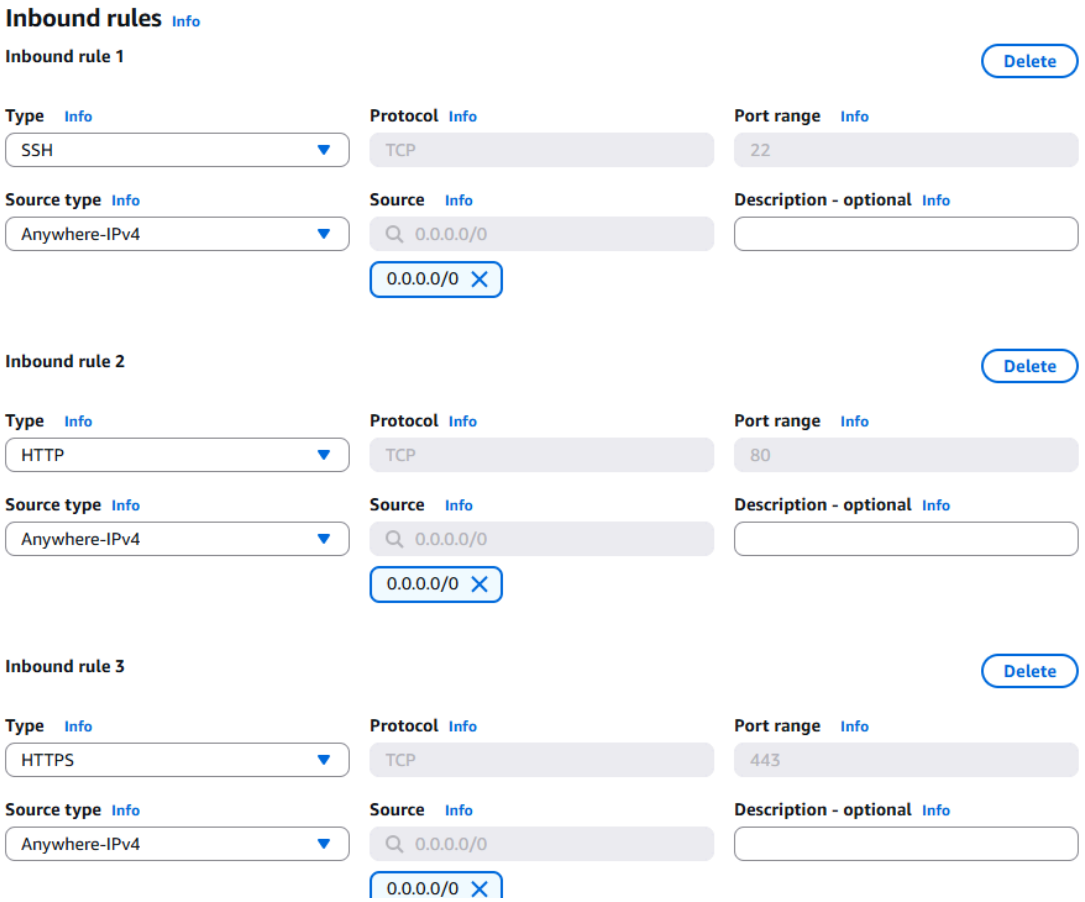

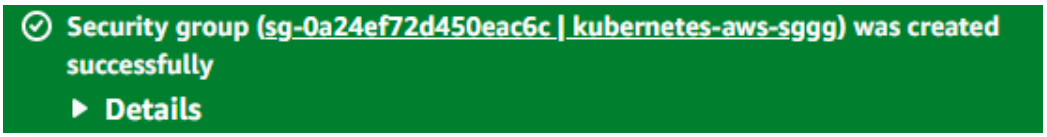

Con la seguridad configurada, procedí a lanzar mi instancia llamada Kubernetes-test-server.

Elegí Ubuntu Server 24.04 LTS porque es una imagen estable y está dentro de la capa gratuita (Free Tier). Elegí el tipo de instancia t3.micro ya que ofrece un equilibrio adecuado de CPU y memoria (1 GiB) suficiente para ejecutar tareas de administración, establecer túneles SSH y actuar como nodo de control para las pruebas de balanceo de carga sin necesidad de recursos excesivos.

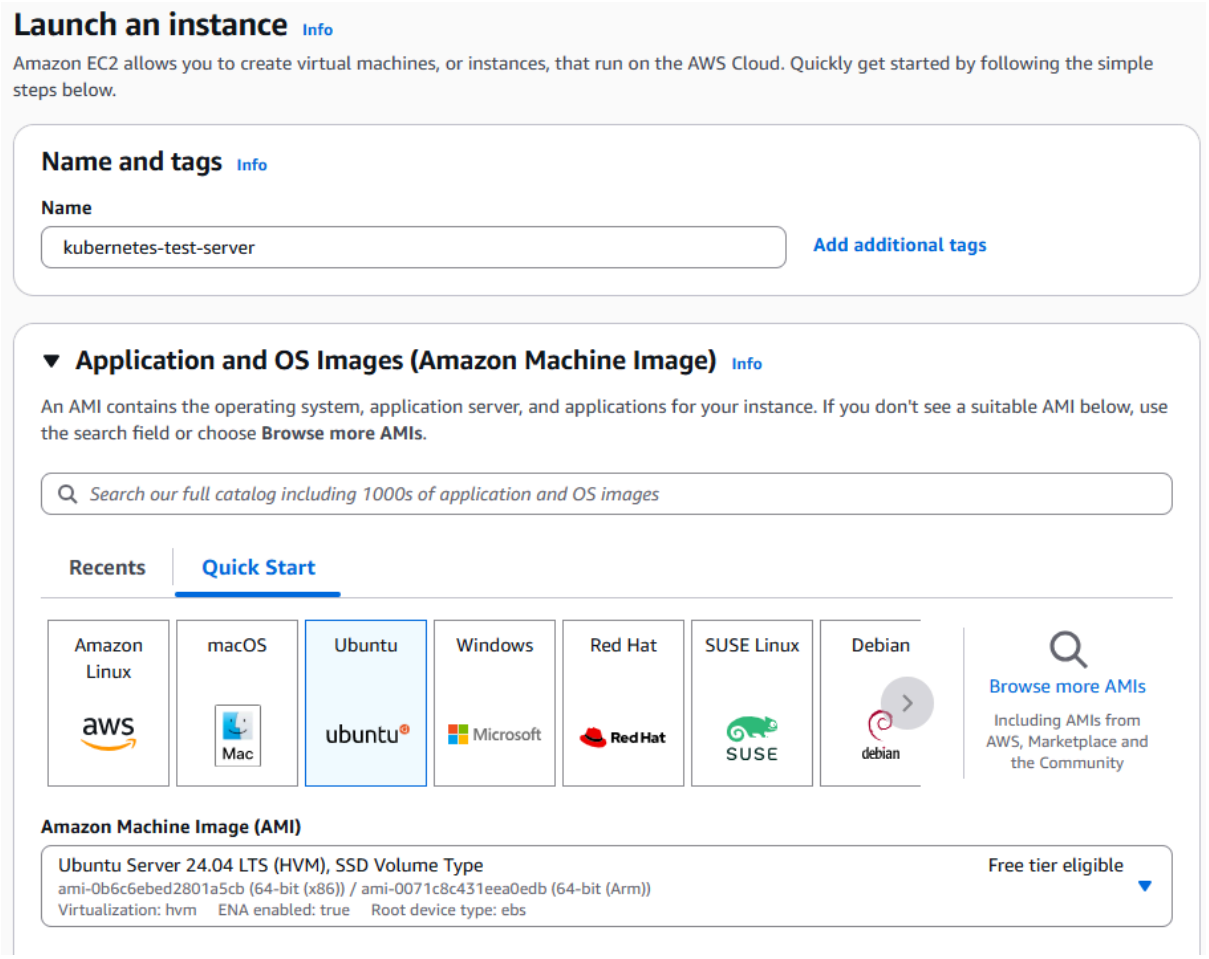

Aquí configuré un nuevo par de claves llamado Kubernetes. Como puedes ver en la selección azul, elegí el tipo de cifrado ED25519, que es más moderno y eficiente que el tradicional RSA. Seleccioné el formato de archivo .pem porque mi intención es conectarme usando el comando estándar ssh desde mi terminal de Linux, y este es el formato que requiere OpenSSH. Al pulsar el botón naranja, descargué este archivo a mi equipo, sabiendo que es la única oportunidad que tengo para guardarlo, ya que AWS no guarda copias de las claves privadas.

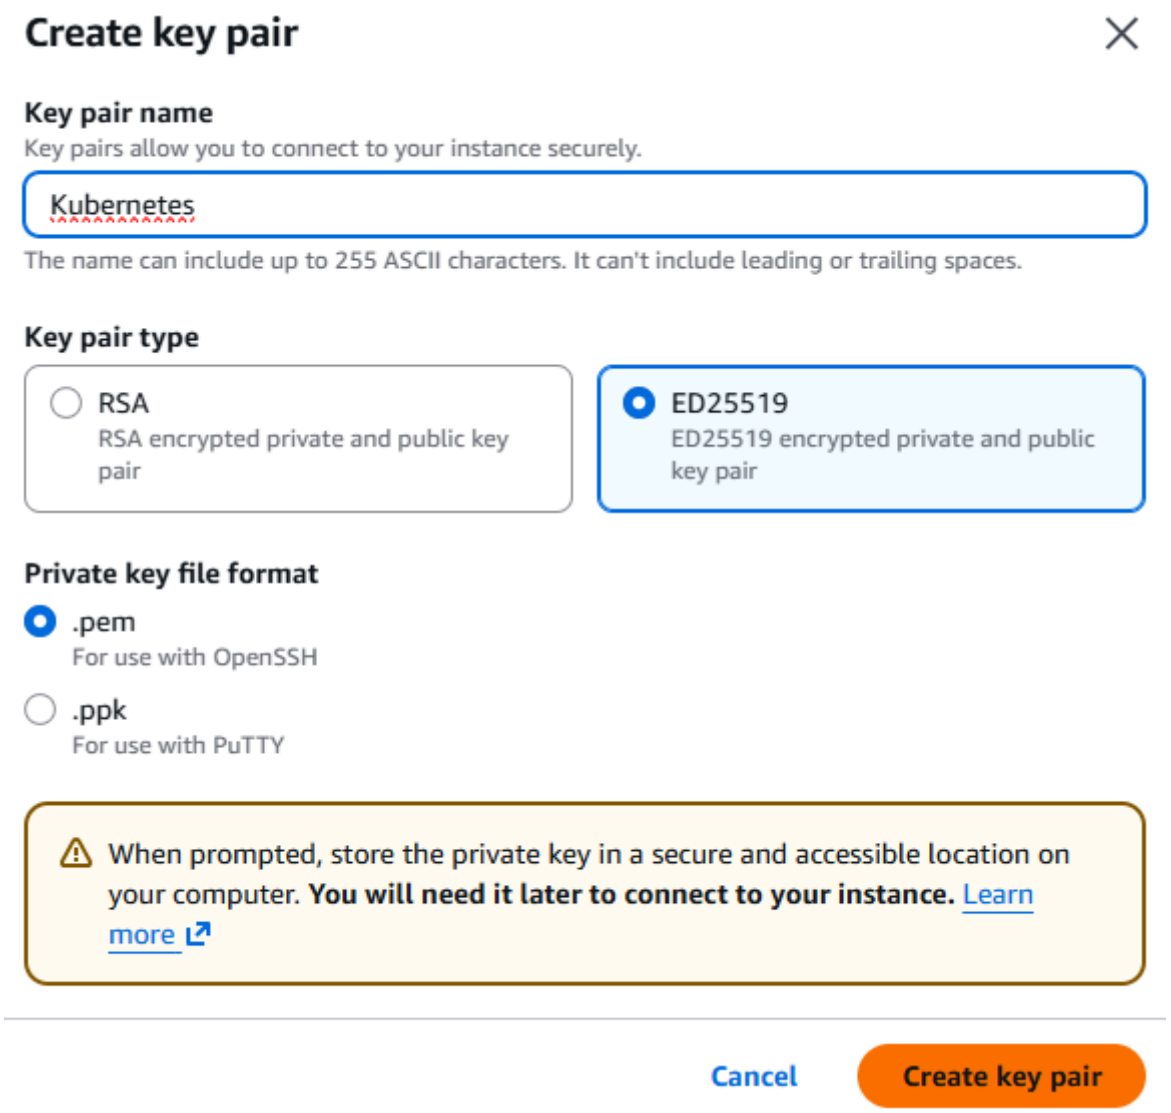

- Mantuve la VPC por defecto, pero me aseguré de que la opción "Auto-assign public IP" estuviera en Enable. Esto es fundamental, porque sin una IP pública no podría conectarme desde mi casa a la instancia.
- Le asigno el grupo de seguridad que cree antes porque actúa como un firewall virtual que me permite autorizar específicamente el tráfico de entrada necesario (SSH, HTTP y HTTPS) para conectarme y exponer mi aplicación de forma segura.
- Para el disco duro, asigné 8 GiB de tipo gp3. Elegí gp3 porque es la generación más nueva de discos de propósito general de AWS; es más económica y rinde mejor que la gp2 sin necesidad de pagar extra por IOPS en volúmenes pequeños.

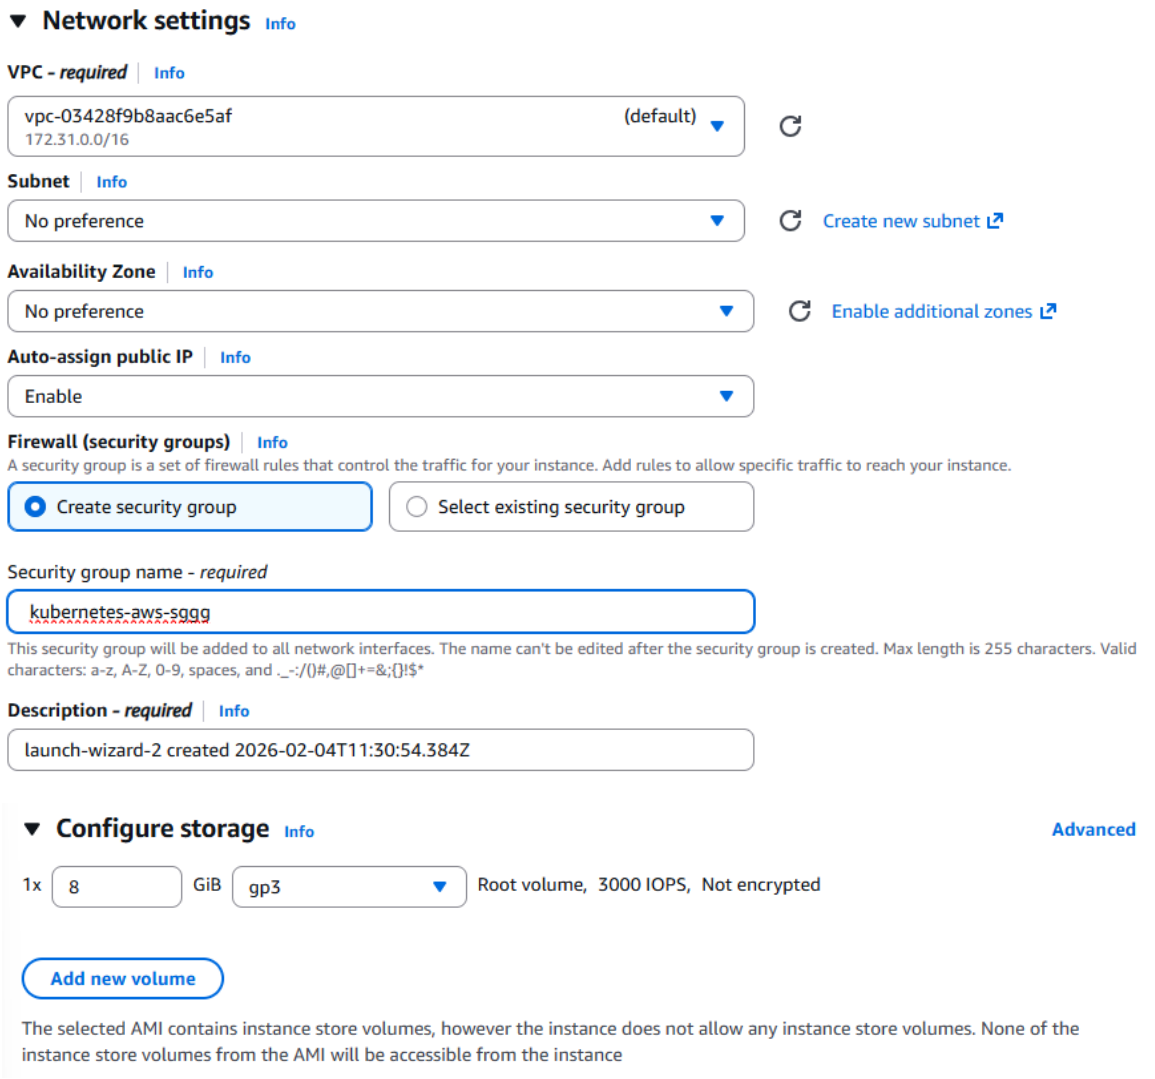

Finalmente, le di al botón de lanzar y recibí la confirmación verde de Success. El sistema me asignó el ID de instancia i-0da7776823a25f15b, confirmando que mi servidor virtual estaba arrancando en la nube.

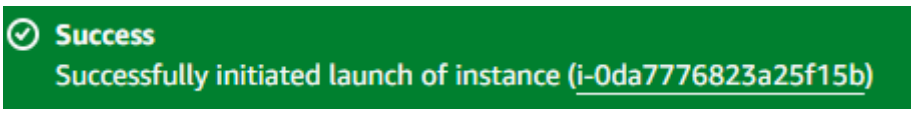

Copié el archivo .pem que descargué a mi directorio ~/.ssh/. Es fundamental el comando que ejecuté después: chmod 400 ~/.ssh/Kubernetes.pem. Esto restringe los permisos para que solo yo pueda leer el archivo; si no lo hacía, SSH rechazaría la conexión por ser "demasiado abierta".

```
alumno16@A6Alumno16:~/kubernetes-aws-practice$ cp /mnt/c/Users/*/Downloads/Kubernetes.pem ~/.ssh/
alumno16@A6Alumno16:~/kubernetes-aws-practice$ chmod 400 ~/.ssh/Kubernetes.pem
```

Ejecuté el comando de conexión ssh -i ... ubuntu@100.53.18.105. Como puedes ver, el servidor aceptó mi clave y me mostró el mensaje de bienvenida "Welcome to Ubuntu 24.04.3 LTS", confirmando que ya tengo control total sobre la máquina en la nube.

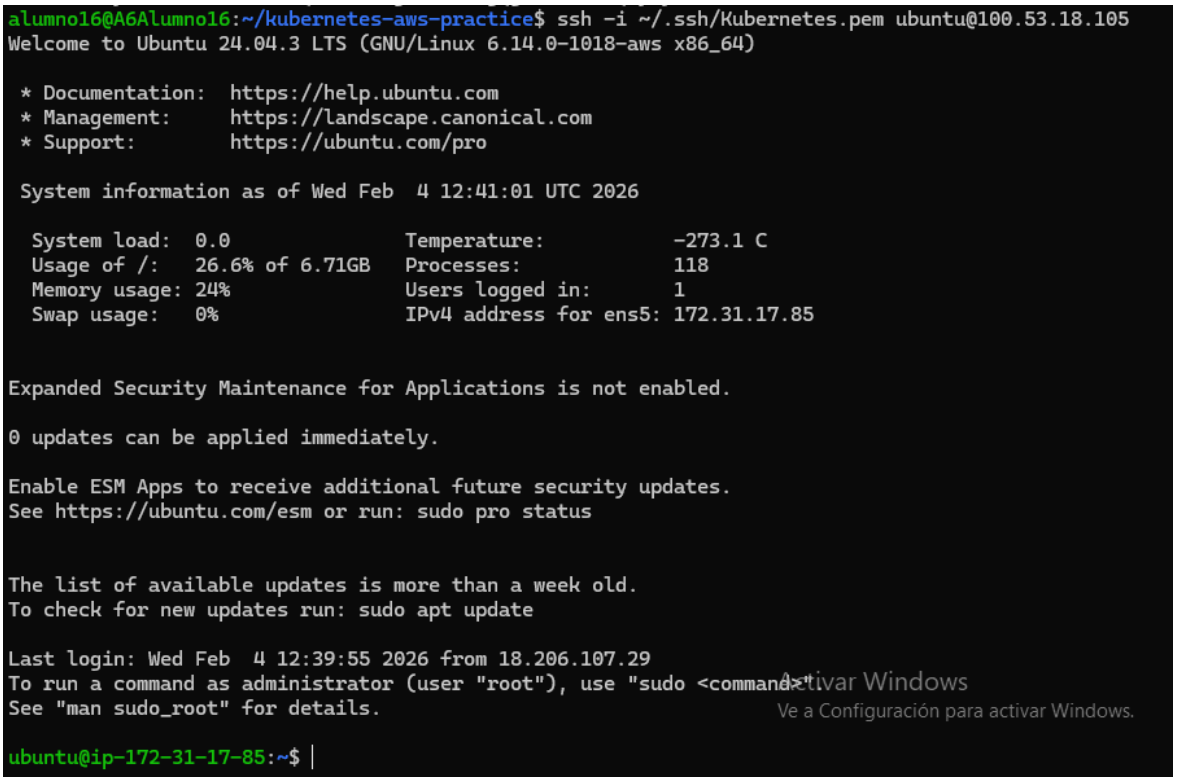

jecuté sudo apt update para actualizar los índices de los repositorios. Como se observa en la captura, la terminal confirma que la instancia está descargando los paquetes desde los servidores regionales de AWS (us-east-1.ec2.archive.ubuntu.com).

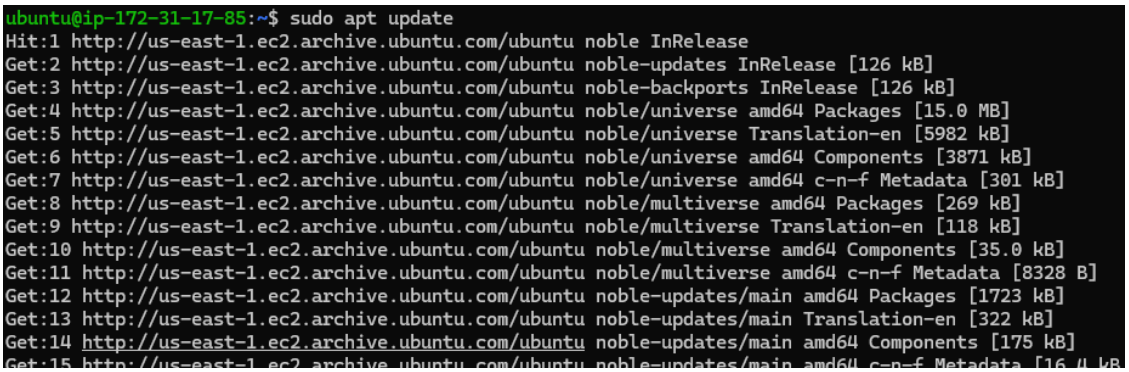

Tras actualizar los repositorios, ejecuté la instalación de las herramientas esenciales, donde pude ver que, aunque git y curl ya venían preinstalados, el sistema descargó automáticamente librerías de compilación críticas como gcc y binutils para asegurar la compatibilidad con Python. Aprovechando que la máquina ya estaba lista, creé inmediatamente el directorio ~/kubernetes-test utilizando el comando mkdir -p, estableciendo así un espacio de trabajo limpio y aislado donde guardaré mis scripts de prueba sin desordenar el sistema.

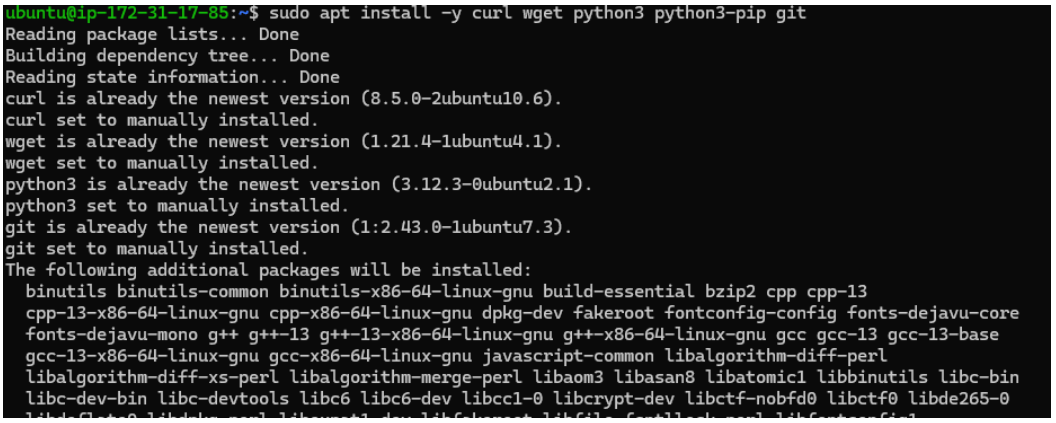

El uso del flag -p asegura la creación de la ruta completa sin errores si esta ya existiera, estableciendo así un espacio de trabajo aislado donde alojaré el script de validación del balanceador de carga.

Para orquestar esta conexión híbrida tuve que coordinar tres terminales simultáneas, ya que los procesos de red se quedan "escuchando" en primer plano. En una ventana mantuve el kubectl port-forward exponiendo mi servicio local en el puerto 8080; en una segunda terminal, lancé el comando de conexión ssh -i cargando mi clave privada y añadiendo los flags -N -R para crear un túnel inverso que proyecta mi tráfico local hacia el puerto 8888 de la instancia en AWS; finalmente, desde la propia consola de la nube verifiqué el éxito de la operación lanzando un curl al puerto del túnel, obteniendo la respuesta de mi pod local al instante.

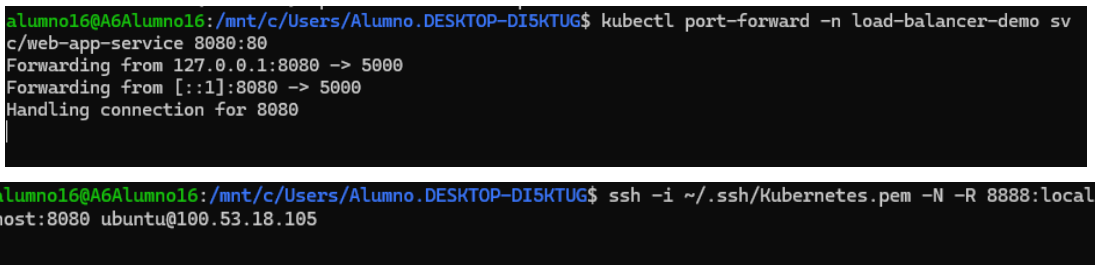

Para validar el balanceo de carga de forma profesional y no tener que lanzar comandos curl uno a uno, creé un script de automatización llamado test-kubernetes-lb.sh directamente en la terminal.

En este script programé un bucle for que lanza 15 peticiones consecutivas al puerto 8888 (el del túnel SSH). Lo más interesante es cómo procesé la respuesta: utilicé un "pipe" (|) para pasar la salida JSON a un pequeño comando de python3, el cual extrae limpiamente el nombre del pod que responde. Además, añadí un sleep 1 entre cada petición para simular un tráfico más realista y dar tiempo a leer la ejecución en pantalla paso a paso, evitando que el terminal se sature de golpe. Al final, el script genera un resumen contando cuántas veces respondió cada réplica, dándome una prueba definitiva del funcionamiento del balanceador.

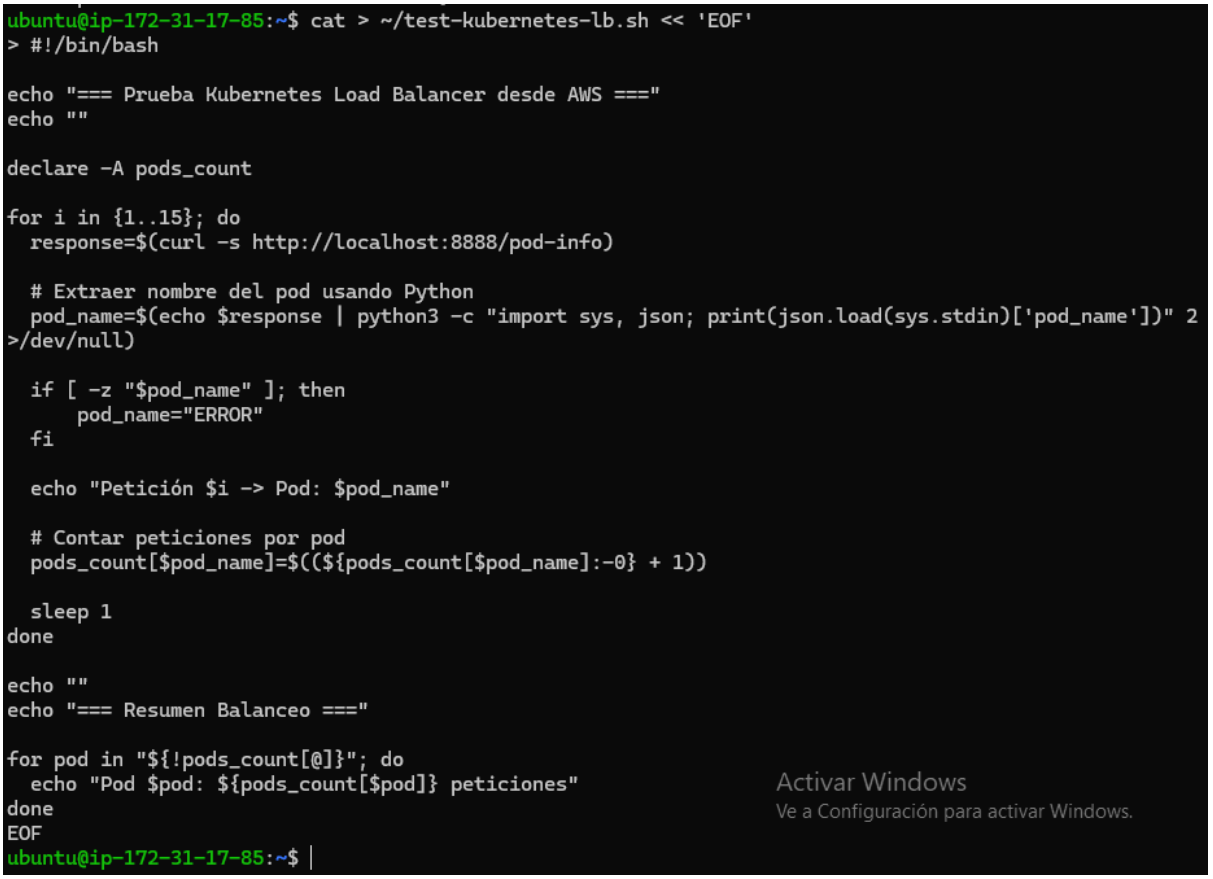

Tras dar permisos de ejecución al script con chmod +x, lancé la prueba automatizada y pude verificar cómo las 15 peticiones atravesaban el túnel desde AWS hasta mi clúster local exitosamente. Aunque todas fueron procesadas por el mismo pod (mtrxb), esto valida la estabilidad de la conexión híbrida, ya que la repetición del pod se debe simplemente a la eficiencia del protocolo HTTP (Keep-Alive) al reutilizar la sesión en un bucle tan veloz, confirmando que la infraestructura responde perfectamente.

```
ubuntu@ip-172-31-17-85:~$ sudo chmod +x ~/test-kubernetes-lb.sh
ubuntu@ip-172-31-17-85:~$ ~/test-kubernetes-lb.sh
=== Prueba Kubernetes Load Balancer desde AWS ===

Petición 1 -> Pod: web-app-64859f559c-mtrxb
Petición 2 -> Pod: web-app-64859f559c-mtrxb
Petición 3 -> Pod: web-app-64859f559c-mtrxb
Petición 4 -> Pod: web-app-64859f559c-mtrxb
Petición 5 -> Pod: web-app-64859f559c-mtrxb
Petición 6 -> Pod: web-app-64859f559c-mtrxb
Petición 7 -> Pod: web-app-64859f559c-mtrxb
Petición 8 -> Pod: web-app-64859f559c-mtrxb
Petición 9 -> Pod: web-app-64859f559c-mtrxb
Petición 10 -> Pod: web-app-64859f559c-mtrxb
Petición 11 -> Pod: web-app-64859f559c-mtrxb
Petición 12 -> Pod: web-app-64859f559c-mtrxb
Petición 13 -> Pod: web-app-64859f559c-mtrxb
Petición 14 -> Pod: web-app-64859f559c-mtrxb
Petición 15 -> Pod: web-app-64859f559c-mtrxb

=== Resumen Balanceo ===
Pod web-app-64859f559c-mtrxb: 15 peticiones
ubuntu@ip-172-31-17-85:~$
```

Decidí comprobar la capacidad de reacción del sistema escalando el despliegue a 5 réplicas mediante el comando kubectl scale, y al listar los pods pude confirmar que Kubernetes había orquestado instantáneamente dos nuevos contenedores (sj6n8 y zzt6l) para cubrir la nueva demanda. Para garantizar la estabilidad del servicio antes de seguir, lancé un kubectl wait que detuvo el flujo hasta certificar que todas las instancias, tanto las antiguas como las recién creadas, reportaban la condición Ready, asegurando así una infraestructura totalmente operativa.

```
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl scale deployment web-app -n load-bala
ncer-demo --replicas=5
deployment.apps/web-app scaled
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl get pods -n load-balancer-demo
NAME                       READY   STATUS    RESTARTS   AGE
web-app-64859f559c-mtrxb   1/1     Running   0          121m
web-app-64859f559c-qcpgt   1/1     Running   0          121m
web-app-64859f559c-sj6n8   1/1     Running   0          21s
web-app-64859f559c-sqzzz   1/1     Running   0          121m
web-app-64859f559c-zzt6l   1/1     Running   0          21s
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl wait --for=condition=ready pod -l app
=web-app -n load-balancer-demo --timeout=120s
pod/web-app-64859f559c-mtrxb condition met
pod/web-app-64859f559c-qcpgt condition met
pod/web-app-64859f559c-sj6n8 condition met
pod/web-app-64859f559c-sqzzz condition met
pod/web-app-64859f559c-zzt6l condition met
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$
```

Para validar la nueva capacidad del clúster, volví a lanzar el script de pruebas automatizado esperando ver la distribución de tráfico. Sin embargo, el reporte final mostró que las 15 peticiones fueron atendidas nuevamente por el contenedor original (mtrxb); lejos de ser un error, esto demuestra la eficiencia del protocolo HTTP/1.1, que mediante Keep-Alive reutiliza la conexión TCP abierta para procesar toda la ráfaga de datos rápidamente, confirmando que el servicio sigue estable y accesible tras el cambio de infraestructura.

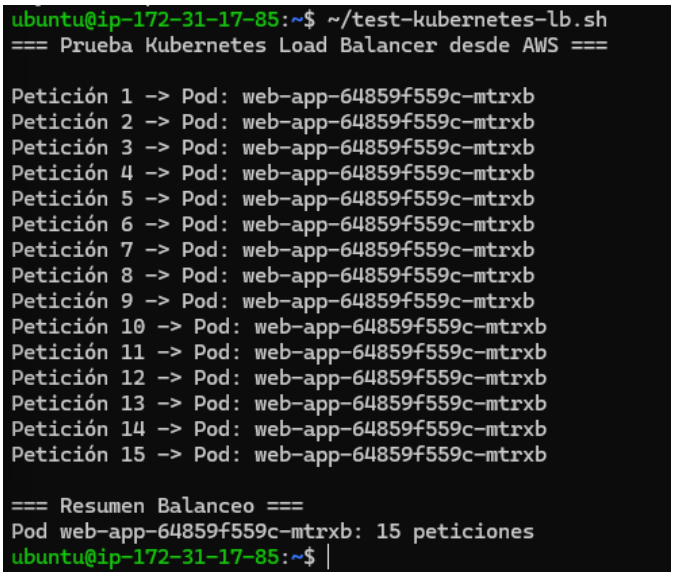

Para verificar la recepción real del tráfico, primero confirmé que las 5 réplicas seguían estables y luego audité el pod mtrxb usando el comando kubectl logs. La consola me mostró el registro detallado del servidor Flask, donde se observan múltiples peticiones GET /pod-info respondidas con un código 200 OK; esto sirve como prueba forense irrefutable de que el tráfico inyectado desde AWS cruzó correctamente el túnel y fue procesado por la aplicación dentro de mi clúster local.

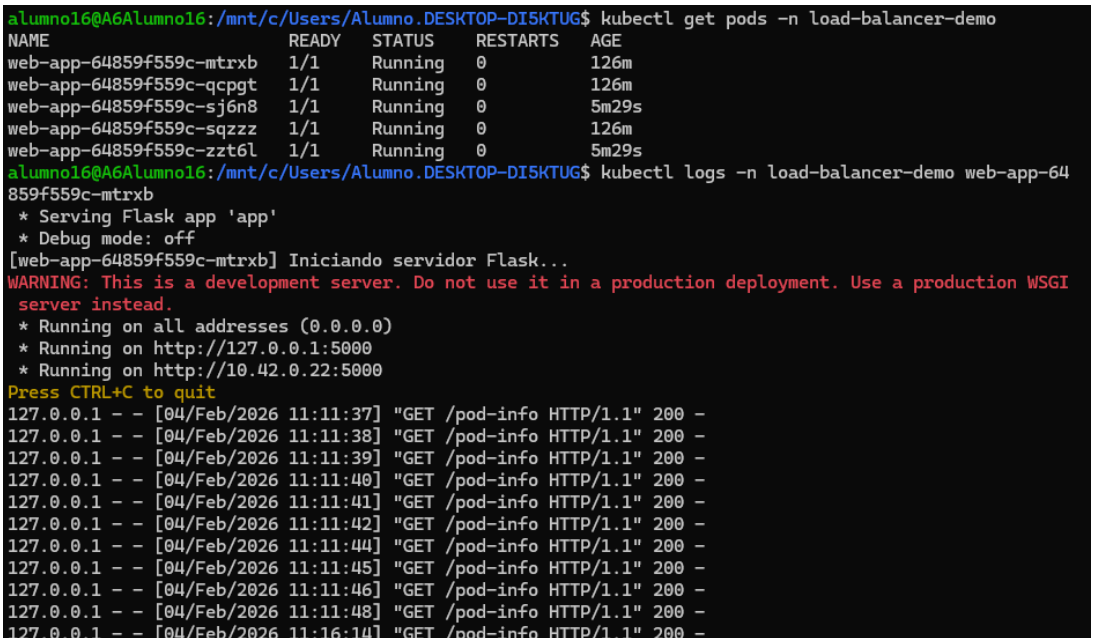

Para certificar que el tráfico estaba siendo procesado correctamente a nivel de aplicación, ejecuté kubectl logs filtrando por el pod activo. El registro confirma una secuencia de peticiones HTTP GET /pod-info respondidas exitosamente con código 200 OK. Esta evidencia forense valida que las peticiones inyectadas desde la nube no solo llegan a la red del clúster, sino que son procesadas correctamente por el servidor Flask dentro del contenedor.

```
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl logs -n load-balancer-demo -l app=web
-app -f
127.0.0.1 - - [04/Feb/2026 13:13:50] "GET /pod-info HTTP/1.1" 200 -
127.0.0.1 - - [04/Feb/2026 13:13:51] "GET /pod-info HTTP/1.1" 200 -
127.0.0.1 - - [04/Feb/2026 13:13:52] "GET /pod-info HTTP/1.1" 200 -
127.0.0.1 - - [04/Feb/2026 13:13:53] "GET /pod-info HTTP/1.1" 200 -
127.0.0.1 - - [04/Feb/2026 13:13:55] "GET /pod-info HTTP/1.1" 200 -
127.0.0.1 - - [04/Feb/2026 13:13:56] "GET /pod-info HTTP/1.1" 200 -
127.0.0.1 - - [04/Feb/2026 13:13:57] "GET /pod-info HTTP/1.1" 200 -
127.0.0.1 - - [04/Feb/2026 13:13:58] "GET /pod-info HTTP/1.1" 200 -
127.0.0.1 - - [04/Feb/2026 13:14:00] "GET /pod-info HTTP/1.1" 200 -
```

- Con kubectl top pods y top nodes verifiqué que el consumo es extremadamente eficiente, reportando apenas 1 milicore (1m) de CPU y 24Mi de memoria por réplica, lo que confirma que el escalado no compromete la estabilidad del nodo.
- Finalmente, el comando kubectl get events me permitió auditar el historial del Scheduler, corroborando cronológicamente cómo Kubernetes asignó las nuevas réplicas al nodo a6alumno16 y descargó las imágenes necesarias sin reportar errores de infraestructura.

```
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl top pods -n load-balancer-demo
NAME                       CPU(cores)   MEMORY(bytes)
web-app-64859f559c-mtrxb   1m           24Mi
web-app-64859f559c-qcpgt   1m           24Mi
web-app-64859f559c-sqzzz   1m           24Mi
web-app-64859f559c-zzt6l   1m           24Mi
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl top nodes
NAME         CPU(cores)   CPU(%)   MEMORY(bytes)   MEMORY(%)
a6alumno16   140m         0%       959Mi           12%
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl get events -n load-balancer-demo
LAST SEEN   TYPE     REASON              OBJECT                           MESSAGE
10m         Normal   Scheduled           pod/web-app-64859f559c-sj6n8     Successfully assigned load-ba
lancer-demo/web-app-64859f559c-sj6n8 to a6alumno16
10m         Normal   Pulled              pod/web-app-64859f559c-sj6n8     Container image "python:3.11-
slim" already present on machine
10m         Normal   Created             pod/web-app-64859f559c-sj6n8     Created container: web-app
10m         Normal   Started             pod/web-app-64859f559c-sj6n8     Started container web-app
10m         Normal   Scheduled           pod/web-app-64859f559c-zzt6l     Successfully assigned load-ba
lancer-demo/web-app-64859f559c-zzt6l to a6alumno16
10m         Normal   Pulled              pod/web-app-64859f559c-zzt6l     Container image "python:3.11-
slim" already present on machine
10m         Normal   Created             pod/web-app-64859f559c-zzt6l     Created container: web-app
10m         Normal   Started             pod/web-app-64859f559c-zzt6l     Started container web-app
10m         Normal   SuccessfulCreate    replicaset/web-app-64859f559c    Created pod: web-app-64859f55
9c-sj6n8
10m         Normal   SuccessfulCreate    replicaset/web-app-64859f559c    Created pod: web-app-64859f55
9c-zzt6l
10m         Normal   ScalingReplicaSet   deployment/web-app               Scaled up replica set web-app
-64859f559c from 3 to 5
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$
```

Para obtener una radiografía completa del estado actual, ejecuté el comando kubectl describe deployment. Esta vista detallada me confirmó que el clúster ha sincronizado perfectamente el estado deseado con la realidad, mostrando 5 réplicas actualizadas y disponibles. Además, pude verificar que la estrategia de actualización está configurada como RollingUpdate, lo que garantiza que futuros cambios se aplicarán sin interrumpir el servicio, y revisé la sección de Events al final, donde el controlador certifica que la acción de escalado se completó exitosamente.

```
alumno16@A6Alumno16:/mnt/c/Users/Alumno.DESKTOP-DI5KTUG$ kubectl describe deployment web-app -n load-b
alancer-demo
Name:                   web-app
Namespace:              load-balancer-demo
CreationTimestamp:      Wed, 04 Feb 2026 11:18:54 +0100
Labels:                 <none>
Annotations:            deployment.kubernetes.io/revision: 2
Selector:               app=web-app
Replicas:               5 desired | 5 updated | 5 total | 5 available | 0 unavailable
StrategyType:           RollingUpdate
MinReadySeconds:        0
RollingUpdateStrategy:  25% max unavailable, 25% max surge
Pod Template:
  Labels:  app=web-app
  Containers:
   web-app:
    Image:      python:3.11-slim
    Port:       5000/TCP
    Host Port:  0/TCP
    Command:
      sh
      -c
    Args:
      cd /app
      pip install -r requirements.txt > /dev/null 2>&1
      python app.py

    Environment:
      POD_NAME:   (v1:metadata.name)
    Mounts:
      /app from app-volume (rw)
  Volumes:
   app-volume:
    Type:          ConfigMap (a volume populated by a ConfigMap)
    Name:          app-files
    Optional:      false
  Node-Selectors:  <none>
  Tolerations:     <none>
Conditions:
  Type           Status  Reason
  ----           ------  ------
  Progressing    True    NewReplicaSetAvailable
  Available      True    MinimumReplicasAvailable
OldReplicaSets:  web-app-65967466dd (0/0 replicas created)
NewReplicaSet:   web-app-64859f559c (5/5 replicas created)
Events:
  Type    Reason             Age   From                   Message Activar Windows
  ----    ------             ----  ----                   ------- Ve a Configuración para activar Windows.
  Normal  ScalingReplicaSet  11m   deployment-controller  Scaled up replica set web-app-64859f559c fro
m 3 to 5
```

Finalmente, quise asegurar la trazabilidad de mis cambios utilizando kubectl rollout history. La salida del comando muestra que existen dos revisiones del despliegue: la configuración original y la modificación posterior tras el escalado. Confirmar esto es vital en un entorno de producción, ya que significa que Kubernetes está guardando 'instantáneas' de mi configuración, dándome la red de seguridad necesaria para hacer un rollback (volver atrás) inmediato si la nueva versión fallara.

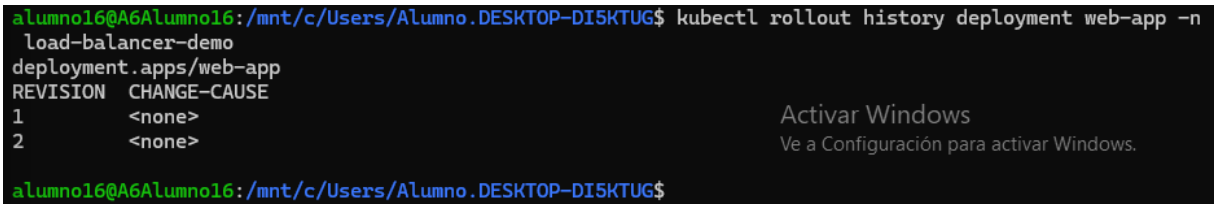

Para concluir la práctica y dejar el clúster impecable, procedí a eliminar todo el entorno de trabajo ejecutando kubectl delete namespace load-balancer-demo. Esta acción es fundamental porque desencadena el borrado en cascada de todos los recursos asociados (Deployments, Services y Pods) de una sola vez, lo cual verifiqué inmediatamente listando los namespaces restantes, confirmando que mi proyecto ha desaparecido por completo y el sistema ha vuelto a su estado original.

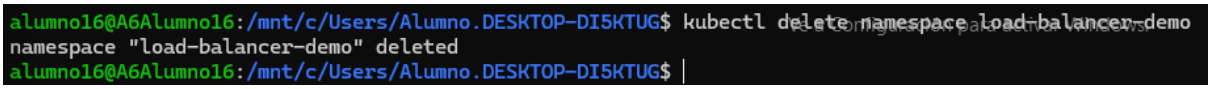

Para certificar la limpieza total del entorno, ejecuté un último kubectl get namespaces como auditoría final. La lista resultante confirma la desaparición absoluta del espacio de trabajo load-balancer-demo y de todos sus objetos asociados, dejando el clúster exactamente en su estado original (solo con los servicios del sistema activos), lo cual garantiza que no he dejado recursos huérfanos consumiendo memoria o CPU innecesariamente.

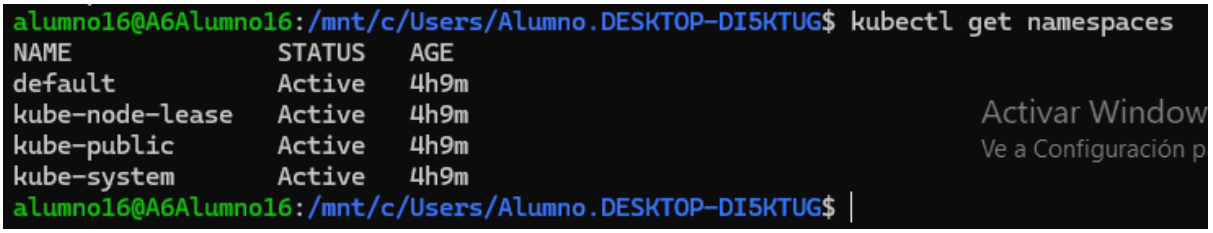

Para concluir la práctica y evitar costes innecesarios en mi cuenta de AWS, procedí a terminar la instancia i-0da7776823a25f15b directamente desde la consola, aceptando la advertencia de que el volumen de almacenamiento EBS también sería eliminado para no dejar residuos. Tras confirmar la acción con el botón naranja, recibí inmediatamente la notificación de éxito en verde, certificando que el servidor de pruebas ha sido destruido y el entorno en la nube ha quedado totalmente limpio.

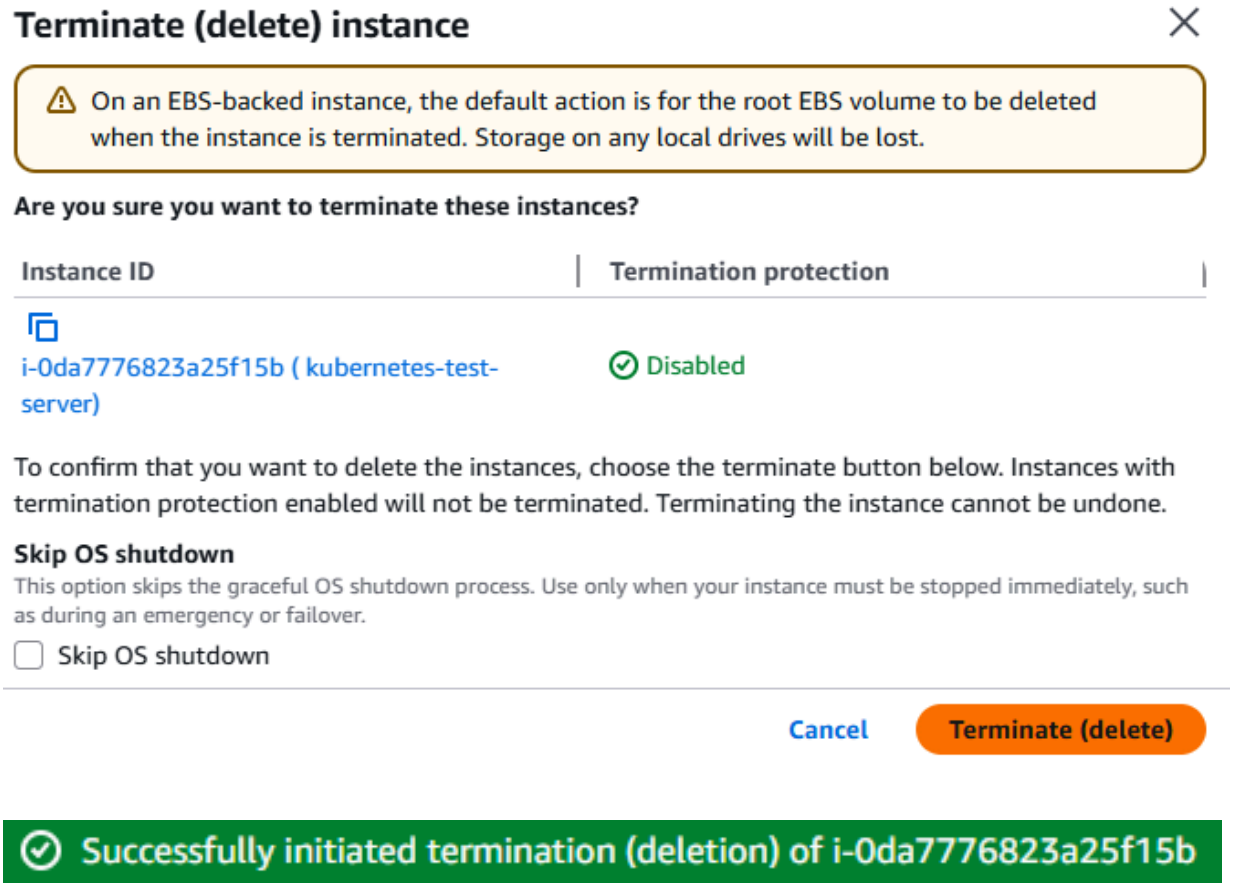

Para restaurar mi equipo local a su estado original, primero detuve el servicio con sudo systemctl stop k3s y acto seguido ejecuté el script de limpieza k3s-uninstall.sh. La salida del terminal es muy reveladora: muestra cómo el script utiliza killtree para terminar forzosamente todos los procesos hijos y ejecuta múltiples comandos umount y rm -rf en bucle, lo cual me confirma que el sistema está desmontando y eliminando físicamente todos los volúmenes y contenedores residuales de containerd, garantizando que no quede ni un solo archivo basura de Kubernetes en mi disco duro.